

# 化学反应中 3D 分子的原子索引映射研究



米思璇 (253107030012)<sup>\*</sup>, 巫世杰 (253107070021)<sup>\*</sup>, 熊文博 (240107140024)<sup>\*</sup>

上海创智学院

米思璇：数据集与传统物理方法基线构建、PPT 设计、最终报告写作

巫世杰：EGNN 模型实现与评测、代码调优、最终报告写作

熊文博：Diffusion 模型实现与评测、代码调优、最终报告写作

**摘要:** 分子原子索引映射是计算化学中的基础性问题，其核心在于确定两个化学成分相同但原子索引顺序未知分子的原子对应关系。由于分子在空间中存在任意旋转平移及构象变化，传统基于物理启发式规则的方法难以处理复杂的结构差异。本研究建立了一个全面的基准测试框架，旨在评估并提升分子原子索引映射的准确性。我们基于 RMSD 库评测了 Distance、QML 与 Inertia-Hungarian 三种常见的物理规则算法。同时，提出并实现了两种基于深度学习的解决方案：一种是基于 E(3) 等变图神经网络 EGNN 的方法，利用几何等变性提取结构特征并结合匈牙利算法进行全局映射求解；另一种是结合注意力机制的扩散概率模型，通过渐进式去噪过程从噪声中恢复映射矩阵。实验基于 Reaction Graph Depth 1 (RGD1)、Transition1x (T1x) 以及 Radical Reaction Dataset (RDB19-Rad) 开源数据集进行。结果表明，传统 Inertia-Hungarian 算法在 RGD1 数据集上的准确率为 23.47%，而 EGNN 模型将其提升至 68.09%，基于扩散模型的方法更是达到了 85.58% 的分子原子索引映射准确率。研究证实了数据驱动的几何深度学习方法能够有效解决分子原子索引映射的歧义性难题，实现了从不可用状态到具备实际应用价值的跨越。

**课程信息:** Coding with AI

**提交日期:** 2026 年 1 月 9 日

## 目录

|                     |    |
|---------------------|----|
| 1 引言                | 2  |
| 2 相关工作简述            | 2  |
| 3 数据处理              | 3  |
| 4 评价指标              | 4  |
| 5 方法                | 4  |
| 5.1 传统物理方法          | 4  |
| 5.2 深度学习方法          | 5  |
| 6 实验细节              | 7  |
| 6.1 EGNN 实验设置       | 8  |
| 6.2 Diffusion 实验设置  | 8  |
| 7 结果与分析             | 8  |
| 7.1 EGNN 编码器训练收敛性分析 | 9  |
| 7.2 混合扩散模型训练动态分析    | 9  |
| 7.3 Benchmark 结果与讨论 | 10 |
| 8 总结                | 11 |
| 参考文献                | 11 |

<sup>0\*</sup> 所有作者对本工作具有同等贡献。

## 1 引言

化学反应的本质是化学键的断裂与重组，实现反应物与生成物分子间原子的精准一一映射，是解析化学反应机理、理解物质转化过程的核心关键。这一问题不仅在材料科学、药物设计以及星际化学等前沿领域具有重要的应用价值，更是当前“AI for Science”范式下利用人工智能加速科学发现的重要切入点。

在微观尺度的基元反应研究中，存在着一个显著的“数据不对称”现象：通过现有的量子化学计算或高通量实验手段，获取反应物与生成物的静态三维平衡态结构是相对容易的 [1, 2]。从理论上讲，一旦确立了反应前后原子级别的一一对应关系（即正确的原子映射），结合爬升图像轻推弹性带（CI-NEB）[3] 等插值算法，计算反应路径、定位过渡态结构以及预测反应能垒等关键动力学信息将变得在计算上可行。然而，这一逻辑链条中缺失且最为棘手的一环恰恰是获取映射本身。由于分子在反应过程中会经历剧烈的构象扭曲、化学键的断裂生成以及在三维空间中的任意旋转平移，如何从两个看似独立且形态各异的三维点云中恢复出隐含的化学对应关系，本质上是一个极其复杂的几何匹配与组合优化问题。传统方法往往难以精确求解这一问题，这成为了制约自动化反应机理搜索与高通量化学计算的主要瓶颈。

从数学角度定义，给定两个化学成分同构的分子  $\mathcal{M}_A$  和  $\mathcal{M}_B$ ，它们分别表示为  $\mathcal{M}_A = (E_A, C_A)$  和  $\mathcal{M}_B = (E_B, C_B)$ 。其中  $E_A, E_B \in \mathbb{R}^N$  代表原子序数集合，取值范围在 1 至 118 之间， $C_A, C_B \in \mathbb{R}^{N \times 3}$  代表原子的三维笛卡尔坐标。本研究的目标是学习一个映射函数  $\hat{y} = f_\theta(\mathcal{M}_A, \mathcal{M}_B)$ ，其输出  $\hat{y} \in \{1, \dots, N\}^N$  为原子映射数组，用于指示分子 A 中的原子在分子 B 中的对应索引位置。图 1 展示了该科学问题的数学示意。




图 1 3D 分子的原子索引映射研究任务示意图。

在解决这一问题时，传统物理方法通常依赖于特定的几何启发式规则。例如，Distance 排序法基于一个强几何假设，即认为在两个同构分子中，对应原子到各自质心的几何距离应当保持一致，因此通过计算各原子到对应质心的距离并进行排序来实现一一映射。而 QML 和 Inertia-Hungarian 算法则引入了刚体变换假设，认为正确的原子映射应当使两个分子在经过刚体变换后，在空间上实现最小化学环境描述符或距离的均方根偏差（RMSD）。然而必须指出的是，无论是质心距离一致性还是最小化 RMSD，都仅仅是基于几何运动的一种近似，并非化学反应的本质。真实的化学反应往往伴随着复杂的反应轨迹以及化学键重组，分子结构最可能的演化路径并不一定遵循特定的几何规则。因此，传统方法在处理高度对称分子或复杂变化的反应时，往往因受限于几何假设而难以获得准确的化学映射。

为了突破物理启发式规则的局限，本研究引入了数据驱动的深度学习方法，旨在直接从数据中学习分子发生化学反应的最可能映射模式。我们重点评估了基于 E(3) 等变图神经网络（EGNN）和扩散概率模型（Diffusion）的解决方案。EGNN 通过提取具有旋转平移等变性的几何特征，在不依赖坐标系的情况下捕捉原子的局部化学环境，虽然其训练过程仍常以 RMSD 为监督信号，但其强大的特征提取能力使其能捕捉更细微的局部化学环境差异。而 Diffusion 则进一步将映射问题建模为从噪声中恢复结构信息的生成过程，通过构建混合损失函数并结合交叉注意力机制捕获分子间的长程依赖，完成对复杂化学反应中原子对应关系的精准映射。

为了建立一个全面且严格的基准测试平台，本研究整理了包括 Reaction Graph Depth 1 (RGD1)、Transition1x (T1x) 以及 Radical Reaction Dataset (RDB19-Rad) 在内的 3 个规模与复杂度各异的公开数据集。在数据构建阶段，我们采用了随机打乱原子索引并记录打乱顺序的方式生成训练与验证数据，从而模拟真实的映射场景。本报告将详细阐述上述方法的理论基础与实现细节，并通过多维度的实验指标对比它们与传统方法的性能差异。研究结果显示，深度学习方法特别是扩散模型在准确率和汉明距离指标上均实现了显著的性能提升，有效地解决了刚体对齐与原子重排序的耦合难题，为该领域的算法选择提供了权威的参考依据。

## 2 相关工作简述

在化学反应的原子索引映射研究中，现有的解决方案主要划分为基于三维几何信息的物理方法与基于拓扑结构的图论方法。鉴于本研究聚焦于利用三维空间信息解决原子重排问题，本文将重点回顾基于几何特征的刚体对齐与指派算法，并简要阐明图论方法的适用边界。

针对三维分子的原子对齐问题，几何方法通常将其建模为寻找最优旋转平移矩阵与置换矩阵的联合优化问题。Kabsch [4, 5, 6] 提出的算法奠定了该领域的基础，该方法利用拉格朗日乘数法求解线性最小二乘问题，计算出使两个已配对向量集之间均方根偏差最小化的最优旋转矩阵。然而 Kabsch 算法预设原子对应关系已知，这在处理原子索引打乱的化学反应场景时存在显著局限性。为解决原子对应关系未知的难题，后续研究引入了基于惯性张量的预对齐策略，即 Inertia-Hungarian 方法。该类方法首先利用分子的惯性主轴进行粗粒度的空间对齐，随后将原子匹配问题转化为经典的线性指派问题。如 Crouse 等 [7] 的研究指出，通过高效实现的匈牙利算法或类似的最优指派策略，可在多项式时间内求解出使空间距离成本最小化的原子排列矩阵。这种结合惯性对齐与组合优化的方法虽然在处理刚性分子结构时表现出较高效率，但在面对非刚性形变显著的反应物与生成物时，往往因刚体假设失效而导致映射精度下降。

随着量子化学计算的发展，基于量子机器学习的表示方法为原子映射提供了新的视角。Christensen 等 [8] 提出了利用 FCHL 等原子环境描述符进行匹配的策略。与单纯依赖几何坐标不同，该方法通过计算原子核的高斯多体分布函数来表征局部化学环境，进而通过最小化特征空间内的距离来确定原子对应关系。尽管这种方法在一定程度上克服了纯几何对齐对构象变化的敏感性，但其计算成本较为高昂，且对原子映射效果的提升相对有限。

此外，基于图论的原子映射方法在化学信息学领域亦有广泛应用 [9, 10, 11, 12, 13, 14, 15]。这类方法主要依赖最大公共子结构算法，通过比较分子图的拓扑连接性识别原子同构关系。尽管图匹配算法在处理明确定义的二维分子结构时表现优异，但本研究涉及的三维分子构象数据本质上是仅包含空间坐标的点云信息，缺乏显式的图拓扑连接关系。若要应用基于图论的方法，必须首先通过几何距离阈值或特定化学规则从三维坐标中逆向推断原子间的连接关系。这一从三维空间到二维图结构的解析过程不仅增加了算法流程的复杂度，更不可避免地引入了由键合判断标准差异导致的系统性不确定性。为排除因图结构重构算法不同而引入的干扰变量并确保研究聚焦于三维空间信息的直接利用，纯基于图拓扑的方法以及任何依赖图拓扑信息辅助的三维混合方法均不在本文的讨论范围内。

综上所述，虽然传统的几何方法和量子机器学习方法在特定场景下有效，但其在处理复杂的非刚性形变和大规模反应数据时仍存在理论与计算瓶颈，这正是本研究引入深度学习方法的动机所在。

### 3 数据处理

为确保基准测试的全面性与挑战性，本研究甄选了三个在规模、化学组成及分子复杂度上各具代表性的公开数据集，分别是 Reaction Graph Depth 1 (RGD1) [16]、Transition1x (T1x) [17] 以及 Radical Reaction Dataset (RDB19-Rad) [18]。这些数据集涵盖了从简单的有机小分子到包含杂原子的复杂自由基反应体系，为评估不同算法在分布内 (In-Distribution, ID) 及分布外 (Out-Of-Distribution, OOD) 场景下的鲁棒性提供了坚实基础。

在数据具体的物理化学属性方面，RGD1 数据集包含 176,992 对反应数据，分子规模主要集中在 10 个重原子以内，元素组成涵盖碳 (C)、氢 (H)、氧 (O)、氮 (N) 四种基础元素，是本研究中数据量最大且最具统计意义的训练主体 [16]。Transition1x 数据集相对精简，包含 10,073 对数据，分子规模限制在 7 个重原子以内，主要用于测试模型在小样本场景下的特征提取能力 [17]。为了进一步验证模型的泛化能力，我们引入了 RDB19-Rad 数据集作为分布外测试集，该数据集不仅将分子规模上限扩展至 19 个重原子，还额外引入了硫 (S) 元素，共包含 5,600 对数据，用于检测模型对分布外化学环境和更大尺寸分子的适应性 [18]。表 1 详细汇总了这三个数据集的关键统计信息。

表 1 本研究使用的公开数据集统计信息概览

| 数据集名称     | 元素组成          | 分子规模 (重原子数) | 数据总量    | 训练集 (80%) | 测试集 (20%) |
|-----------|---------------|-------------|---------|-----------|-----------|
| T1x       | C, H, O, N    | $\leq 7$    | 10,073  | 8,058     | 2,015     |
| RGD1      | C, H, O, N    | $\leq 10$   | 176,992 | 141,593   | 35,399    |
| RDB19-Rad | C, H, O, N, S | $\leq 19$   | 5,600   | 4,480     | 1,120     |

针对原始数据，本研究设计了一套标准化的预处理流程。所有经过清洗的数据被统一封装为 AtomMapping 对象，每个对象包含参考分子结构、候选分子结构以及真实的原子映射索引。其中，参考分子与候选分子的结构信息由原子序数向量  $E \in \mathbb{R}^N$  和三维笛卡尔坐标矩阵  $C \in \mathbb{R}^{N \times 3}$  共同描述。为了构建符合真实盲测环境的监督学习任务，我们并未直接使用原始对齐数据，而是对候选分子的原子索引进行了随机打乱处理。具体而言，对于每一个样本对，保持参考分子的原子顺序不变，通过随机生成的置换矩阵对候选分子的原子特征与坐标进行重排，并将该置换操作的逆映射记录为真实的映射索引标签。这一处理方式强制模型必须依据分子的几何与化学特征而非输入顺序来推断原子对应关系。

在实验设置上，为了保证评估结果的公正性与可复现性，我们对所有数据集采用了统一的划分策略。每个数据集均在固定的随机种子下，严格按照 80% 与 20% 的比例划分为训练集与测试集。对于 RGD1 和 Transition1x，模型在 80% 的训练集上进行参数学习，并在 20% 的测试集上评估分布内性能。而对于 RDB19-Rad 数据集，为了严格测试模型的跨域泛化能力，我们并未利用其划分出的 80% 训练集进行任何训练，仅使用其 20% 的测试集进行最终的推理评估。

## 4 评价指标

为了全面量化不同算法在分子原子索引映射任务中的性能表现，本研究从预测成功率、错误程度以及计算成本三个维度建立了评价体系。

首先，我们采用准确率 (Accuracy, Acc.  $\uparrow$ ) 作为衡量模型核心竞争力的首要指标。该指标定义为测试集中预测的原子映射关系与真实映射关系完全一致的分子样本比例。对于包含  $M$  个分子的测试集，设  $\mathbf{y}^{(k)}$  为第  $k$  个分子的真实原子索引向量， $\hat{\mathbf{y}}^{(k)}$  为算法预测的索引向量，则准确率计算如下：

$$\text{Acc.} = \frac{1}{M} \sum_{k=1}^M \mathbb{I}(\hat{\mathbf{y}}^{(k)} = \mathbf{y}^{(k)}) \quad (1)$$

其中  $\mathbb{I}(\cdot)$  为示性函数，仅当分子内所有原子的映射均正确时取值为 1，否则为 0。该指标反映了算法在处理复杂化学结构时实现零错误对齐的能力，是化学反应路径分析等高精度下游任务的先决条件。

其次，为了评估预测结果偏离真实值的程度，我们引入平均汉明距离 (Average Hamming Distance, Avg. HD  $\downarrow$ )。准确率指标对于局部错误过于苛刻，而汉明距离能够细粒度地量化每一个分子中发生错误映射的原子数量。其定义为测试集中所有分子的平均错误原子数：

$$\text{Avg. HD} = \frac{1}{M} \sum_{k=1}^M \sum_{i=1}^{N_k} \mathbb{I}(\hat{y}_i^{(k)} \neq y_i^{(k)}) \quad (2)$$

其中  $N_k$  为第  $k$  个分子的原子总数。较低的汉明距离表明即便模型未能实现完美匹配，其预测结果也更接近真实结构，保留了更多的局部化学对应信息。

最后，考虑到实际工业应用中对于高通量筛选的需求，本研究统计了计算效率 (Computational Efficiency, ms/mol  $\downarrow$ )。该指标记录了算法在单张 H100/H200 显卡或单核高性能 CPU 上完成一次分子对齐推理所需的平均毫秒数。通过对比传统物理迭代算法与深度学习模型的推理耗时，我们能够评估各方法在精度与时间成本之间的权衡，从而为不同算力环境下的算法选择提供参考。

## 5 方法

本研究建立的基准测试框架包含传统物理方法与深度学习方法两类。为了确保化学反应前后原子守恒的基本物理法则，所有基准方法均引入了原子类型硬约束，即仅允许在同种元素（如碳对碳、氢对氢）的原子之间建立映射关系，从而避免了非物理的错误映射。传统物理方法主要依赖于分子的几何不变量、物理化学描述符以及刚体动力学特性，旨在通过显式的规则设计来求解原子映射问题；深度学习方法则通过数据驱动的方式，学习化学反应的隐含规律来解决原子映射问题。

### 5.1 传统物理方法

我们选取了三种代表性的传统算法作为基线，分别为基于质心距离排序的方法（Distance）、基于量子机器学习描述符的方法（QML）以及基于惯性主轴的匈牙利算法（Inertia-Hungarian）。

#### 5.1.1 基于质心距离的排序方法 (Distance)

该方法基于一个朴素的几何假设，即在两个同构分子中，对应原子相对于分子质心的几何位置应当保持拓扑等价（如图 2(a) 所示）。对于给定的分子  $\mathcal{M}$ ，首先计算其所有原子的几何中心（质心） $\bar{C}$ ：

$$\bar{C} = \frac{1}{N} \sum_{i=1}^N C_i \quad (3)$$

随后，算法执行基于元素类型的分层排序策略。首先依据原子序数将参考分子  $\mathcal{M}_A$  和候选分子  $\mathcal{M}_B$  的原子划分为若干个元素子集（如碳原子组、氢原子组等）。在每一个同元素子集内部，计算原子  $i$  到质心的欧几里得距离  $d_i = \|C_i - \bar{C}\|_2$ ，并分别进行升序排列。最终的原子索引映射关系由各子集内的排序秩次直接决定，即  $\mathcal{M}_A$  某元素组中距离质心第  $k$  近的原子，被强制映射到  $\mathcal{M}_B$  对应元素组中距离质心第  $k$  近的原子。该方法计算效率极高，但假设过于理想，且完全忽略了分子的角度信息与局部化学环境。

#### 5.1.2 基于量子机器学习描述符的匹配 (QML)

为了弥补单一几何距离特征的不足，QML 方法引入了包含丰富物理化学信息的原子描述符（如图 2(b) 所示）。该方法不再依赖全局坐标系，而是为每个原子构建具有平移旋转不变性的局部特征向量  $D_i$ （也称作原子环境描述符）。在匹配阶段，同样遵循元素类型约束：



对于分子 A 中的原子  $i$  和分子 B 中的原子  $j$ ，若其元素类型不同，则设定其匹配代价为无穷大；若类型相同，则计算描述符差异作为代价：

$$cost_{ij} = \begin{cases} \|D_i^A - D_j^B\|_2 & \text{if } E_i^A = E_j^B \\ \infty & \text{if } E_i^A \neq E_j^B \end{cases} \quad (4)$$

在此基础上，通过线性分配算法在代价矩阵中寻找最小化总差异的映射组合。相比于 Distance 方法，QML 能够更好地区分不同化学环境下的同种元素 [8]。

### 5.1.3 基于惯性主轴与匈牙利算法 (Inertia-Hungarian)

Inertia-Hungarian 算法是处理刚体对齐问题的经典方案，其核心思想是利用分子的质量分布特征来校准空间姿态（如图 2(c) 所示）。首先计算分子的惯性张量  $I \in \mathbb{R}^{3 \times 3}$ ：

$$I = \sum_{i=1}^N m_i ((r_i^T r_i) \mathbf{I} - r_i r_i^T) \quad (5)$$

通过特征分解获得分子主轴，并将候选分子旋转至与参考分子主轴重合，实现粗粒度的刚体对齐。在对齐后的坐标系中，计算原子间的欧几里得距离矩阵。为了施加元素约束，对每种元素分别构建距离矩阵。最后，应用匈牙利算法（Kuhn-Munkres Algorithm）求解二分图的最大权匹配问题，从而获得满足全局距离最小化的最优置换矩阵  $P$  [4, 7]。




图 2 传统物理方法映射机制示意图。(a) Distance 方法：基于到达质心的距离排序；(b) QML 方法：基于描述符特征空间的向量匹配；(c) Inertia-Hungarian 方法：惯性主轴对齐后的基于匈牙利算法进行距离匹配。

## 5.2 深度学习方法

相比于依赖几何假设的传统方法，深度学习方法旨在通过数据驱动的方式学习原子的高维特征表示，从而捕捉更复杂的化学环境与局部拓扑结构。

### 5.2.1 基于 E(3) 等变图神经网络 (EGNN)

在分子原子对齐任务中，分子结构具有旋转、平移不变性（Invariance）以及旋转等变性（Equivariance）。为了有效提取这些几何特征，本研究采用了 Satorras 等人提出的 E(n) 等变图神经网络 (EGNN) [19]，具体架构如图 3 所示。该模型不需要昂贵的高阶球谐函数表示，而是直接在欧几里得空间中对坐标和特征进行操作，具有较高的计算效率。

**等变图神经网络** 在我们的实现中，参考分子  $\mathcal{M}_A$  与候选分子  $\mathcal{M}_B$  通过共享权重的 EGNN 网络进行编码。对于第  $l$  层网络，输入为节点语义特征  $\mathbf{h}_i^l$  和坐标位置  $\mathbf{x}_i^l$ 。网络的更新规则由以下三个核心方程定义：

首先，进行边消息传递（Edge Message Passing）：不仅考虑节点特征，还将相对距离平方作为具有旋转不变性的几何条件输入到边函数  $\phi_e$  中：

$$\mathbf{m}_{ij} = \phi_e(\mathbf{h}_i^l, \mathbf{h}_j^l, \|\mathbf{x}_i^l - \mathbf{x}_j^l\|^2, a_{ij}) \quad (6)$$

其中  $\phi_e$  为多层感知机（MLP）， $a_{ij}$  为可选的边属性。

其次，进行坐标等变更新（Coordinate Equivariant Update）：基于相对位置向量差和边消息的加权和来更新坐标。由于相对向量  $\mathbf{x}_i^l - \mathbf{x}_j^l$  会随整体旋转而旋转，该步骤保证了输出坐标的 E(3) 等变性：

$$\mathbf{x}_i^{l+1} = \mathbf{x}_i^l + C \sum_{j \neq i} (\mathbf{x}_i^l - \mathbf{x}_j^l) \phi_x(\mathbf{m}_{ij}) \quad (7)$$

其中  $\phi_x$  将边消息映射为标量权重，用于调节相对位置的聚合强度， $C$  为归一化常数（通常取  $1/(N-1)$ ）。

最后，进行节点特征更新（Node Feature Update）：聚合邻域内的边消息，并通过节点函数  $\phi_h$  更新语义特征，该过程保持旋转不变性：

$$\mathbf{h}_i^{l+1} = \phi_h \left( \mathbf{h}_i^l, \sum_{j \neq i} \mathbf{m}_{ij} \right) \quad (8)$$

**训练目标与损失函数** 经过  $L$  层迭代后，模型计算参考分子原子  $i$  与候选分子原子  $j$  之间的余弦相似度，并构建相似度矩阵  $S \in \mathbb{R}^{N \times N}$ 。为了端到端地训练模型，我们采用了交叉熵损失函数（Cross-Entropy Loss）。

具体而言，首先对相似度矩阵  $S$  的每一行进行 Softmax 归一化，得到原子  $i$  匹配到原子  $j$  的预测概率  $\hat{P}_{ij}$ ：


$$\hat{P}_{ij} = \frac{\exp(S_{ij}/\tau)}{\sum_{k=1}^N \exp(S_{ik}/\tau)} \quad (9)$$

其中  $\tau$  为温度系数。损失函数  $\mathcal{L}$  定义为预测概率分布与真实置换矩阵  $P^{gt}$  之间的负对数似然：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N P_{ij}^{gt} \log(\hat{P}_{ij}) \quad (10)$$

通过最小化该损失，模型被迫使参考分子中的每个原子在候选分子中以最高概率指向其真实的对应原子。

**推理与后处理** 在推理阶段，模型输出的概率矩阵  $\hat{P}$  往往不是严格的置换矩阵。为了获得最终的离散映射并保证化学合理性，我们引入了与传统方法一致的元素类型硬约束（即仅保留同元素间的相似度分数），并应用匈牙利算法求解二分图最大权匹配，从而输出满足全局最优性的对齐索引。



**图 3** 基于 EGNN 的网络架构。模型通过等变层更新原子坐标与特征，利用最后层特征计算余弦相似度矩阵，并通过匈牙利算法获得最终的原子对齐索引。

### 5.2.2 基于混合监督的扩散概率模型 (Diffusion)

虽然 EGNN 利用几何等变性有效提取了特征，但将复杂的组合优化问题简化为单次预测可能难以捕捉多模态的映射分布。为此，本研究提出了一种基于生成式扩散模型（Denoising Diffusion Probabilistic Models, DDPM）的解决方案。该方法将原子对齐矩阵的生成建模为一个从高斯噪声中逐步恢复结构的去噪过程，并结合交叉注意力机制捕获分子间的长程依赖 [20, 21]，具体架构如图 4 所示。

**特征编码与交叉注意力** 首先，模型利用图注意力网络（GAT）分别提取参考分子  $\mathcal{M}_A$  和候选分子  $\mathcal{M}_B$  的原子特征  $H_A, H_B$  [22]。为了建立两个分子间的全局上下文联系，我们引入了 Transformer 中的交叉注意力机制 [23]。以  $H_A$  为查询（Query）， $H_B$  为键（Key）和值（Value），计算交互特征：

$$\text{Attention}(H_A, H_B) = \text{softmax} \left( \frac{W_Q H_A (W_K H_B)^T}{\sqrt{d_k}} \right) W_V H_B \quad (11)$$

这一过程使得每个原子的特征都融合了对方的结构信息，为后续的对齐生成提供了丰富的前下文。

**扩散过程建模** 我们将原子对齐任务视为生成一个置换矩阵  $P_0 \in \mathbb{R}^{N \times N}$ 。前向扩散过程：向真实的对齐矩阵  $P_0$  中逐步添加高斯噪声，直至其变为各向同性的高斯分布。在任意时刻  $t$ ，加噪后的矩阵  $P_t$  可由  $P_0$  直接采样得到：

$$q(P_t|P_0) = \mathcal{N}(P_t; \sqrt{\bar{\alpha}_t}P_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad (12)$$

其中  $\bar{\alpha}_t$  为噪声调度参数 [20]。

**反向生成过程**：训练一个神经网络  $\epsilon_\theta(P_t, t, H_A, H_B)$  来预测添加的噪声或直接预测去噪后的  $P_0$ 。本研究采用预测  $\hat{P}_0$  的参数化方式，利用编码后的分子特征条件逐步去除噪声。

**混合损失函数** 为了克服单一去噪损失收敛慢的问题，本研究设计了一种混合监督损失 [?]。除了常规的噪声预测损失外，我们直接对模型预测的去噪矩阵  $\hat{P}_0$  施加显式的结构约束。总损失  $\mathcal{L}_{total}$  定义为：

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{noise} + \lambda_2 (\mathcal{L}_{CE} + \mathcal{L}_{MSE} + \mathcal{L}_{DS}) \quad (13)$$

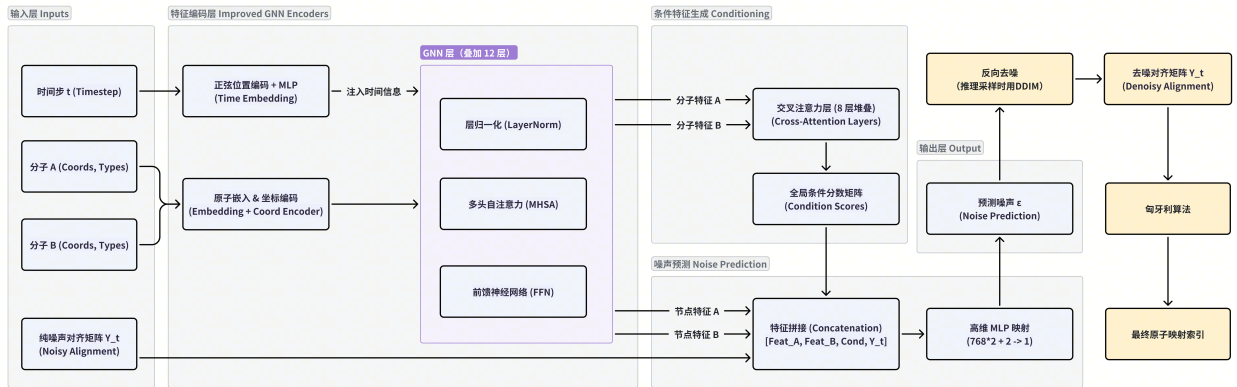
其中：

- $\mathcal{L}_{noise}$ ：预测噪声与真实噪声的均方误差。
- $\mathcal{L}_{CE}$ ：预测矩阵  $\hat{P}_0$  与真实标签  $P_{gt}$  之间的交叉熵损失，用于强化分类准确性。
- $\mathcal{L}_{DS}$ ：双随机约束损失 (Doubly Stochastic Loss)，惩罚行和与列和偏离 1 的情况，确保输出接近置换矩阵。

这种双重监督机制显著提升了训练效率和模型准确率。

**推理与后处理** 在推理阶段，模型从标准高斯噪声  $P_T \sim \mathcal{N}(0, I)$  开始执行反向生成过程。为了解决传统扩散模型采样速度慢的瓶颈，本研究采用了去噪扩散隐式模型 (DDIM) 采样策略 [24]。作为一种确定性采样方法，DDIM 允许在反向过程中跳过中间时间步，例如从训练时的总步数 (如  $T = 100$ ) 中仅选取少量关键步数 (如  $S = 5$ ) 进行迭代，从而实现了约 20 倍的推理加速。

然而，扩散去噪产出的最终矩阵  $\hat{P}_0$  仍由连续的浮点数值构成，并不满足原子映射所需的离散性与一一对应性约束。因此，必须引入后处理步骤。具体而言，我们构建代价矩阵  $C = -\hat{P}_0$  (取负旨在将最大化概率问题转化为最小化代价问题)，并应用匈牙利算法求解二分图的最大权匹配。该算法能够以  $O(N^3)$  的时间复杂度解析出全局最优的离散原子索引排列。对于本研究中涉及的分子规模 ( $N \approx 50$ )，该后处理步骤的耗时通常小于 1 毫秒，在保证输出严格合法的置换矩阵的同时，几乎不增加额外的计算负担。



**图 4** 基于混合监督的扩散对齐模型架构。模型通过交叉注意力融合双分子特征，并在反向扩散过程中利用混合损失函数同时优化噪声预测与结构对齐。

## 6 实验细节

为了保证实验结果的可复现性，本研究在明确的硬件与软件环境下完成了所有模型的训练与评估。以下详细说明 EGNN 模型的实验设置。

## 6.1 EGNN 实验设置

### 6.1.1 实验环境

所有 EGNN 相关的实验均在启智平台分布式训练空间下进行，主要硬件为 20 核 CPU 200GB 内存 1 \* NVIDIA H200 ( 141GB )。软件环境基于 Linux 操作系统构建，采用 Python 3.10 作为编程语言，并基于 PyTorch 2.6.0 深度学习框架实现模型算法。项目的完整代码、预训练模型权重及具体环境配置文件已开源至 GitHub 仓库<https://github.com/SixuanMi/3D-Molecule-Align>。

### 6.1.2 训练流程与参数设置

实验数据严格按照第 3 节所述策略进行划分，即 80% 用于模型训练，20% 用于验证与测试。

模型采用 Adam 优化器进行参数更新，并配合余弦退火学习率调度策略以优化收敛过程。训练损失函数采用交叉熵损失，旨在最大化预测原子与真实原子的匹配概率。详细参数配置列于表 2。

表 2 模型训练参数详细设置。

| 参数项         | 数值     |
|-------------|--------|
| 优化器         | Adam   |
| 初始学习率       | 0.001  |
| 批次大小        | 128    |
| 训练轮次        | 50     |
| 隐藏层维度       | 128    |
| GNN 层数      | 4      |
| 温度系数 $\tau$ | 0.07   |
| 学习率调整耐心值    | 3      |
| 学习率衰减因子     | 0.5    |
| 早停耐心值       | 5      |
| 随机种子        | 未设定    |
| 可训练参数总量     | 0.48 M |

## 6.2 Diffusion 实验设置

### 6.2.1 实验环境

所有扩散模型相关的实验均在启智平台分布式训练空间下进行。硬件设施主要包含 120 核 CPU、1600GB 内存以及 NVIDIA H100 ( 80GB 显存 ) 8 张。软件环境构建于 Linux 操作系统之上，采用 Python 3.10 作为核心编程语言，并基于 PyTorch 2.7.0 深度学习框架实现模型算法。项目的具体运行环境与依赖信息正在整理并同步至 GitHub 仓库 <https://github.com/SixuanMi/3D-Molecule-Align>。

### 6.2.2 训练流程与参数配置

实验数据划分严格遵循第 3 节所述策略。为了提升大规模数据下的训练效率，本次实验基于 PyTorch 框架采用了分布式数据并行 ( Distributed Data Parallel, DDP ) 策略，在多块 GPU 上同步进行模型参数更新。

模型优化采用 AdamW 优化器，该方法在处理高维参数空间时表现出优异的收敛稳定性。学习率调度策略选用余弦退火算法，初始学习率设定为  $1 \times 10^{-4}$ ，并随训练进程平滑衰减，最低衰减至  $1 \times 10^{-6}$ 。为了进一步降低显存占用并加速计算，训练全程启用了自动混合精度 ( AMP ) 技术。同时，为了防止梯度爆炸导致的训练不稳定，引入了阈值为 1.0 的梯度裁剪机制。

与传统扩散模型不同，本研究提出并应用了一种混合目标函数来驱动模型训练。该损失函数由两部分构成：一部分是基于均方误差的噪声预测损失，用于恢复高斯噪声中的原始信号；另一部分是直接作用于恢复结构上的对齐损失，包含交叉熵项与双随机矩阵约束。二者通过权重系数  $\lambda = 0.5$  进行加权求和，从而在保证去噪能力的同时强化模型对分子几何结构的显式感知。详细参数配置列于表 3。

## 7 结果与分析

本节将详细阐述模型在训练过程中的收敛特性与性能表现，并结合基准测试结果对所提方法的有效性进行验证。首先分析 EGNN 编码器与扩散模型生成器的训练动态，随后分析标准测试集上进行的 benchmark 实验。



表 3 混合扩散模型训练超参数详细设置。

| 参数项              | 数值                 |
|------------------|--------------------|
| 优化器              | AdamW              |
| 学习率调度策略          | Cosine Annealing   |
| 初始学习率            | $1 \times 10^{-4}$ |
| 权重衰减             | $1 \times 10^{-5}$ |
| 批次大小             | 512                |
| 训练轮次             | 500                |
| 扩散时间步数           | 1000               |
| 对齐损失权重 $\lambda$ | 0.5                |
| 梯度裁剪阈值           | 1.0                |
| 混合精度训练           | 开启                 |
| 随机种子             | 未设定                |
| 可训练参数总量          | 95.72 M            |

## 7.1 EGNN 编码器训练收敛性分析

为了评估图神经网络编码器对分子几何特征的提取能力，我们记录了训练集与验证集在 50 个轮次内的损失值与准确率变化，如图 5 所示。从损失曲线（左图）可以观察到，模型在训练初期表现出极快的收敛速度，训练损失在前 5 个轮次内迅速下降，表明 EGNN 能够有效捕捉原子间的局部拓扑结构与空间位置关系。随着训练进行，损失下降趋势逐渐平缓并在第 41 轮次出现明显的阶梯式下降，这与预设的学习率衰减调度策略相吻合。准确率曲线（右图）进一步证实了模型的泛化能力。验证集准确率稳步提升，最终稳定在 91.5% 左右，而训练集准确率则达到了 94% 以上。注意，这里的准确率是原子节点级别的准确率，并非分子级别的整体准确率。尽管训练集与验证集之间存在细微的性能间隙，但两条曲线始终保持同步上升趋势且未出现剧烈的震荡或发散，说明模型在 0.48 M 参数量的限制下，成功学习到了具有鲁棒性的分子特征表示，且未发生严重的过拟合现象，成功触发早停机制。




图 5 EGNN 模型训练损失即节点级准确率变化。

## 7.2 混合扩散模型训练动态分析

扩散模型的训练过程旨在协同优化噪声预测与结构对齐两个目标。图 6 展示了对数坐标系下，总损失及各项损失在 500 个训练轮次内的变化趋势。图中蓝色实线与红色实线分别代表训练集与验证集的总损失，绿色与紫色虚线则分别指示训练过程中的噪声预测分量与对齐分量。

观察各分项损失的演变可知，噪声预测损失（绿色虚线）在训练初期呈现出极其陡峭的下降态势，并在约 20 个轮次内迅速收敛至  $10^{-2}$  量级。这一现象表明，模型对高斯噪声分布规律的学习较为迅速，能够快速建立基础的去噪能力。相对而言，对齐损失（紫色虚

线)的收敛曲线较为平缓且持续下降周期更长,揭示了从噪声背景中恢复精确原子对应关系的复杂性,确立了其作为模型优化主导任务的地位。

进一步分析验证集总损失(红色实线)的走势,模型在前150个轮次内处于高效学习阶段,验证损失与训练损失保持同步下降。随后验证集曲线进入平台期,并伴随训练损失的持续降低出现了极其缓慢的上升趋势。考虑到纵坐标采用了对数尺度,这种验证损失的波动在数值幅度上极为微小,仅表现为轻微的过拟合倾向,并未出现发散性的性能恶化。因此,实验坚持执行了完整的500个训练轮次,以在保证泛化能力相对稳定的前提下,尽可能挖掘模型对复杂分子结构对齐任务的拟合潜力。




图6 Diffusion 模型训练损失变化。

### 7.3 Benchmark 结果与讨论

为了全面评估所提方法的有效性,我们在T1x、RGD1两个ID数据集以及RDB19-Rad OOD数据集上,将本文提出的EGNN与Diffusion模型,与三种传统物理基线方法Distance、QML、Inertia-Hungarian进行了对比测试。详细的实验结果如表4所示,评价指标涵盖准确率(Acc.)、平均汉明距离(Avg. HD)以及单分子推理耗时(ms/mol)。

表4 不同方法在同分布与跨分布数据集上的性能对比。表中最优结果以**粗体**显示,次优结果以下划线标示。

| 方法                      | T1x (ID)      |             |             | RGD1 (ID)     |             |             | RDB19-Rad (OOD) |             |             |
|-------------------------|---------------|-------------|-------------|---------------|-------------|-------------|-----------------|-------------|-------------|
|                         | Acc. ↑        | Avg. HD ↓   | Time ↓      | Acc. ↑        | Avg. HD ↓   | Time ↓      | Acc. ↑          | Avg. HD ↓   | Time ↓      |
| Distance                | 2.18%         | 8.12        | <b>0.03</b> | 0.41%         | 11.21       | <b>0.03</b> | 0.00%           | 19.08       | <b>0.03</b> |
| QML                     | 23.23%        | 3.87        | 0.58        | 16.70%        | 4.74        | 1.07        | 13.66%          | 6.14        | 3.66        |
| Inertia-Hungarian       | 27.00%        | 5.14        | <u>0.42</u> | 23.47%        | 6.88        | 0.48        | 29.73%          | 7.35        | <u>0.50</u> |
| <b>EGNN (Ours)</b>      | <u>43.57%</u> | <u>2.38</u> | 0.62        | <u>68.09%</u> | <u>1.13</u> | <u>0.25</u> | <u>34.64%</u>   | <u>3.11</u> | 1.49        |
| <b>Diffusion (Ours)</b> | <b>75.50%</b> | <b>0.71</b> | 16.63       | <b>85.58%</b> | <b>0.42</b> | 16.33       | <b>57.32%</b>   | <b>1.70</b> | 17.23       |

在传统物理方法的对比中,Inertia-Hungarian算法在准确率指标上表现相对较优,在T1x与RDB19-Rad数据集上分别达到27.00%和29.73%的准确率;而QML方法则在平均汉明距离上优于其他物理基线,例如在T1x上取得了3.87的结果。然而,深度学习方法在各项关键指标上均实现了对传统物理基线的显著超越。以RGD1数据集为例,EGNN与Diffusion模型分别取得了68.09%和85.58%的准确率,远超Inertia-Hungarian的23.47%。这种性能优势在RDB19-Rad分布外数据集上同样显著,Diffusion模型依然保持了57.32%的高准确率与1.70的低汉明距离,证明了基于学习的方法具备更强的鲁棒性与泛化能力。此外,实验数据呈现出明显的规模效应,深度学习模型在数据量最丰富的RGD1训练分布下表现最佳,这验证了数据驱动策略在解决复杂分子对齐问题上的有效性。

针对本文提出的两种模型,推理效率呈现出截然不同的特性。EGNN的推理耗时在不同数据集上表现出显著差异:在样本量较少的T1x与RDB19-Rad数据集上,其平均耗时分别为0.62 ms和1.49 ms,略高于部分传统方法;然而在包含数万测试样本的RGD1数据集

上, EGNN 的平均耗时骤降至 0.25 ms, 不仅显著优于 Inertia-Hungarian 的 0.48 ms, 更远快于 QML 的 1.07 ms。这一现象有力地说明, EGNN 在小样本测试中的较高平均耗时主要受限于模型加载与数据预处理等固定启动开销, 而非模型本身的计算复杂度。这意味着在实际的大规模高吞吐量应用中, 经过工程优化的 EGNN 完全具备超越传统物理算法的速度潜力。

相比之下, Diffusion 模型由于涉及多步迭代去噪过程, 其平均推理耗时稳定在 16 ms/mol 左右。尽管这一数值高于 EGNN, 但考虑到其在所有测试集上均取得了最优的准确率与汉明距离指标 (例如在 RGD1 上将平均汉明距离降至 0.42), 这种时间成本的增加换取了对齐精度的质变。鉴于在完整的复杂化学反应研究过程中, 对齐步骤通常不是计算性能的瓶颈, Diffusion 模型所提供的高精度对齐结果使其在对准确性要求严格的应用场景中具有不可替代的价值。

## 8 总结

本研究聚焦于计算化学中的基础性难题——分子原子索引映射, 针对传统物理启发式方法在处理分子空间旋转、平移及构象变化时的局限性, 构建了全面的基准测试框架, 并提出了基于深度几何学习的创新解决方案。实验对比了 Distance、QML 与 Inertia-Hungarian 三种物理规则算法, 并深入评估了所提出的 E(3) 等变图神经网络 EGNN 与结合注意力机制的扩散概率模型在解决该问题上的有效性。

研究结果表明, 数据驱动的方法能够有效提取分子几何特征, 显著克服了结构差异带来的映射歧义。在 RGD1、T1x 及 RDB19-Rad 数据集上的广泛评测显示, 深度学习模型性能全面超越传统基线。特别是在 RGD1 数据集上, Inertia-Hungarian 算法的准确率仅为 23.47%, 而利用几何等变性与匈牙利算法结合的 EGNN 模型将其大幅提升至 68.09%; 通过渐进式去噪过程恢复映射矩阵的扩散模型更是达到了 85.58% 的准确率。

此外, 效率分析揭示了两种模型不同的应用定位。EGNN 在消除启动开销后展现出与传统方法相当甚至更优的推理吞吐量, 适用于大规模数据的初步快速筛选; 而扩散模型虽然单分子推理耗时约为 16 ms, 但其以计算成本换取了对齐精度的质变, 更适用于对准确性要求严苛的精细化分析场景。综上所述, 本研究提出的方法不仅在性能指标上实现了突破, 更为复杂化学反应研究提供了兼顾效率与精度的多样化技术选择。

综上所述, 本研究证实了数据驱动的几何深度学习方法能够从根本上解决分子原子索引映射的准确性瓶颈, 成功将该任务的解决方案从早期的理论探索推进至具备实际应用价值的新阶段, 为计算化学领域的自动化分子处理流程提供了强有力的技术支撑。

## 参考文献

- [1] G. Landrum, "Rdkit: Open-source cheminformatics." <http://www.rdkit.org>.
- [2] N. M. O'Boyle, M. Banck, C. A. James, C. Morley, T. Vandermeersch, and G. R. Hutchison, "Open babel: An open chemical toolbox," *Journal of Cheminformatics*, vol. 3, no. 1, pp. 1–14, 2011.
- [3] V. Ásgeirsson, B. Birgisson, R. Björnsson, U. Becker, F. Neese, C. Riplinger, and H. Jónsson, "Nudged elastic band method for finding minimum energy paths of transitions with change in electron spin," *Journal of Chemical Theory and Computation*, vol. 17, no. 8, pp. 4929–4945, 2021.
- [4] W. Kabsch, "A solution for the best rotation to relate two sets of vectors," *Acta Crystallographica Section A: Crystal Physics, Diffraction, Theoretical and General Crystallography*, vol. 32, no. 5, pp. 922–923, 1976.
- [5] K. L. Damm and H. A. Carlson, "Gaussian-weighted rmsd superposition of proteins: a structural comparison for flexible proteins and predicted protein structures," *Biophysical Journal*, vol. 90, no. 12, pp. 4558–4573, 2006.
- [6] A. Pujol et al., "Alignment of three-dimensional molecules using an image recognition algorithm," *Journal of Molecular Graphics and Modelling*, vol. 23, no. 2, pp. 189–196, 2004.
- [7] D. F. Crouse et al., "Target association and tracking using the inertia-hungarian algorithm," *IEEE Transactions on Aerospace and Electronic Systems*, vol. 52, no. 2, pp. 1409–1422, 2016.
- [8] A. S. Christensen, L. A. Bratholm, F. A. Faber, and O. Anatole von Lilienfeld, "Fchl revisited: Faster and more accurate quantum machine learning potentials," *The Journal of Chemical Physics*, vol. 152, no. 4, p. 044107, 2020.
- [9] M. Hattori, Y. Okuno, S. Goto, and M. Kanehisa, "Heuristics for chemical compound matching," *Genome Informatics*, vol. 14, pp. 144–153, 2003.
- [10] T. Sato and Y. Sakakibara, "Novel alignment method of small molecules using the hopfield neural network," *Journal of Chemical Information and Computer Sciences*, vol. 43, no. 2, pp. 453–460, 2003.
- [11] Y. Song, X. Zhang, et al., "Learning symmetry-aware atom mapping in chemical reactions through deep graph matching," *Journal of Cheminformatics*, vol. 16, no. 1, p. 25, 2024.
- [12] G. Javahery et al., "Reactionmap: An efficient atom-mapping algorithm for chemical reactions," *Journal of Chemical Information and Modeling*, vol. 54, no. 2, pp. 369–377, 2014.

- [13] J. Jaworska *et al.*, "Automatic mapping of atoms across both simple and complex chemical reactions," *Nature Communications*, vol. 10, no. 1, p. 1434, 2019.
- [14] Y. Shi *et al.*, "Bidirectional graphormer for reactivity understanding: Neural network trained to reaction atom- to- atom mapping task," *Journal of Chemical Information and Modeling*, vol. 62, no. 18, pp. 4353–4363, 2022.
- [15] R. Prasad *et al.*, "Dracon: Disconnected graph neural network for atom mapping in chemical reactions," *ChemRxiv*, 2020.
- [16] Q. Zhao, S. M. Vaddadi, M. Woulfe, L. A. Ogunfowora, S. S. Garimella, O. Isayev, and B. M. Savoie, "Comprehensive exploration of graphically defined reaction spaces," *Scientific Data*, vol. 10, no. 1, p. 155, 2023.
- [17] M. Schreiner, A. Bhowmik, T. Vegge, J. Busk, and O. Winther, "Transition1x- a dataset for building generalizable reactive machine learning potentials," *Scientific Data*, vol. 9, no. 1, p. 779, 2022.
- [18] A. Menon and M. Bergeler, "Accurately predicting barrier heights for radical reactions in solution using deep graph networks," *The Journal of Physical Chemistry A*, vol. 128, no. 39, pp. 8384–8403, 2024.
- [19] V. G. Satorras, E. Hoogeboom, and M. Welling, "E(n) equivariant graph neural networks," in *Proceedings of the 38th International Conference on Machine Learning*, pp. 9323–9332, PMLR, 2021.
- [20] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in Neural Information Processing Systems*, vol. 33, pp. 6840–6851, 2020.
- [21] M. A. Ketata, C. Laue, R. Mamas, H. S. de Azambuja, K. Wu, G. Corso, C. Marquet, R. Barzilay, and T. S. Jaakkola, "Diffdock- pp: Rigid protein-protein docking with diffusion models," *arXiv preprint arXiv:2304.06174*, 2023.
- [22] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Lio, and Y. Bengio, "Graph attention networks," in *International Conference on Learning Representations*, 2018.
- [23] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [24] J. Song, C. Meng, and S. Ermon, "Denoising diffusion implicit models," in *International Conference on Learning Representations*, 2021.